构建三层神经网络分类器实现地表覆盖图像分类报告

姚程缤
大数据学院
25210980125@m.fudan.edu.cn

Abstract

本实验面向遥感图像地表覆盖分类任务，在不依赖任何深度学习框架的前提下，从零实现了一个三层全连接神经网络（MLP）分类器。实验基于 EuroSAT RGB 数据集，该数据集包含 10 个地表覆盖类别共 27,000 张 64×64 像素卫星图像。在方法层面，模型实现了完整的前向传播与手动推导的反向传播，并集成了 SGD 优化器、L2 权重衰减正则化与 Step Decay 学习率衰减策略；数据预处理采用分层划分与 z-score 标准化。通过网格搜索确定最优超参数组合。最优模型在独立测试集上取得约 66.22% 的整体分类准确率，其中 Forest 类别准确率最高，Highway 类别最低。实验结果表明，MLP 因丢失图像空间结构信息存在明显过拟合，推测引入卷积结构有望进一步提升性能。

1 任务概述

本次作业任务是在不借助任何已有的深度学习框架下，完成搭建一个三层神经网络分类器，并在给定的遥感图像数据集 EuroSAT 上训练与测试，实现 10 种类别的分类。总结而言，本次实验的核心任务是要分别实现数据加载处理模块，模型定义模块，超参数搜索模块与测试评估模块。

2 数据加载与处理模块

2.1 EuroSAT 数据集

EuroSAT 是基于 ESA Sentinel-2 卫星图像构建的地表覆盖分类数据集。本次实验使用其 RGB 子集，共包含 10 个类别、27,000 张 64×64 像素的 JPEG 格式图像，各类别样本数量如下表1所示。

2.2 数据预处理

首先需要对数据进行预处理，具体使用 PIL 库读取每张图像并转换为 RGB 格式。然后为了能够适应 MLP 模型的输入维度要求，需将原始 64×64×3 的三维张量展平为一维特征向量，展开后维度为 $d = 64\times64\times3 = 12{,}288$。

为了提升模型训练的稳定性与收敛速度，并避免由于输入范围过大而导致的梯度更新不稳定问题，还需要将原始像素值从 [0,255] 线性映射至 [0,1]。

表 1: 类别及样本数统计

类别（英文）	中文含义	样本数
AnnualCrop	一年生农作物	3,000
Forest	森林	3,000
HerbaceousVegetation	草本植被	3,000
Highway	高速公路	2,500
Industrial	工业区	2,500
Pasture	牧场	2,000
PermanentCrop	多年生农作物	2,500
Residential	住宅区	3,000
River	河流	2,500
SeaLake	海洋/湖泊	3,000
合计		**27,000**

为了实验数据分布保持均衡，实验还需要将数据分层采样，按 70%、15% 和 15% 的比例划分为训练集、验证集和测试集，其中训练集包含 18,900 个样本，验证集和测试集各包含 4,050 个样本。

在完成数据集划分后，进一步采用训练集统计得到的均值和标准差对所有样本进行 z-score 标准化处理。该方法能够将输入数据转换为均值为 0、标准差为 1 的分布形式，从而减小不同特征之间的尺度差异，增强模型优化过程的稳定性。其定义如下：

$$x' = \frac{x - \mu}{\sigma} \tag{1}$$

式中，x 为原始输入值，μ 和 σ 分别表示训练集的均值与标准差，x' 为标准化后的输出值。

3 模型构建

3.1 三层全连接神经网络实现

本实验实现了一个三层全连接神经网络（Three-Layer MLP），其结构为：

$$\text{Input} \to \text{Linear}_1 \to \text{Activation}_1 \to \text{Linear}_2 \to \text{Activation}_2 \to \text{Linear}_3 \to \text{Softmax}$$

其中，输入样本首先被展平为维度为 12,288 的向量，随后依次通过两层隐藏层和一层输出层。两个隐藏层使用相同的隐藏维度 h，输出层维度为 10，对应 10 个分类类别。

3.1.1 前向传播

设输入矩阵为 $X \in \mathbb{R}^{N \times d}$，其中 N 为批量大小，$d = 12{,}288$。网络的前向传播过程可表示为：

$$Z_1 = XW_1 + b_1, \tag{2}$$
$$A_1 = \phi(Z_1), \tag{3}$$
$$Z_2 = A_1W_2 + b_2, \tag{4}$$
$$A_2 = \phi(Z_2), \tag{5}$$
$$Z_3 = A_2W_3 + b_3, \tag{6}$$

其中，$\phi(\cdot)$ 表示激活函数，本文支持 `ReLU`、`Sigmoid` 和 `Tanh` 三种激活函数。输出层不再使用额外激活函数，其输出 Z_3 作为 logits 输入 Softmax 分类器。

3.1.2 参数初始化

根据所选激活函数不同，模型采用不同的参数初始化策略：

- 当激活函数为 `ReLU` 时，使用 He 初始化：

$$W \sim \mathcal{N}\left(0, \frac{2}{\text{fan_in}}\right) \tag{7}$$

- 当激活函数为 `Sigmoid` 或 `Tanh` 时，使用 Xavier 初始化：

$$W \sim \mathcal{N}\left(0, \frac{2}{\text{fan_in} + \text{fan_out}}\right) \tag{8}$$

所有偏置项均初始化为 0。

3.1.3 反向传播

在反向传播过程中，模型接收损失函数关于 logits 的梯度 $\frac{\partial L}{\partial Z_3}$，并利用链式法则逐层计算各参数梯度。具体实现中，梯度被存储在 `grads` 字典中，便于后续参数更新。

对于输出层：

$$\frac{\partial L}{\partial W_3} = A_2^\intercal \frac{\partial L}{\partial Z_3}, \tag{9}$$
$$\frac{\partial L}{\partial b_3} = \sum_{i=1}^{N} \frac{\partial L}{\partial Z_3^{(i)}} \tag{10}$$

随后，梯度继续向前传播到第二层和第一层隐藏层：

$$\frac{\partial L}{\partial A_2} = \frac{\partial L}{\partial Z_3} W_3^\top, \tag{11}$$

$$\frac{\partial L}{\partial Z_2} = \frac{\partial L}{\partial A_2} \odot \phi'(Z_2), \tag{12}$$

$$\frac{\partial L}{\partial W_2} = A_1^\top \frac{\partial L}{\partial Z_2}, \tag{13}$$

$$\frac{\partial L}{\partial b_2} = \sum_{i=1}^{N} \frac{\partial L}{\partial Z_2^{(i)}}, \tag{14}$$

$$\frac{\partial L}{\partial A_1} = \frac{\partial L}{\partial Z_2} W_2^\top, \tag{15}$$

$$\frac{\partial L}{\partial Z_1} = \frac{\partial L}{\partial A_1} \odot \phi'(Z_1), \tag{16}$$

$$\frac{\partial L}{\partial W_1} = X^\top \frac{\partial L}{\partial Z_1}, \tag{17}$$

$$\frac{\partial L}{\partial b_1} = \sum_{i=1}^{N} \frac{\partial L}{\partial Z_1^{(i)}}. \tag{18}$$

其中，$\odot$ 表示逐元素乘法。

3.1.4 SGD 优化器与 L2 正则化约束

本实验采用引入 L2 权重衰减正则化的随机梯度下降（SGD）完成模型参数迭代更新，参数更新规则如下：

$$\boldsymbol{W} \leftarrow \boldsymbol{W} - \eta \cdot \left(\frac{\partial \mathcal{L}}{\partial \boldsymbol{W}} + \lambda \boldsymbol{W} \right) \tag{19}$$

$$\boldsymbol{b} \leftarrow \boldsymbol{b} - \eta \cdot \frac{\partial \mathcal{L}}{\partial \boldsymbol{b}} \tag{20}$$

其中 η 为当前迭代学习率，λ 为 L2 正则化系数。

3.1.5 Mini-batch 批量训练流程

训练阶段采用 Mini-batch 梯度下降：每一轮 epoch 开始前，首先对全部训练数据集执行全局随机打乱；随后设置固定批量大小 $B = 128$，将数据集切分为若干独立 mini-batch。对每个 mini-batch，依次执行前向传播、损失计算、反向传播、参数全局更新完整流程。相较于全量批量梯度下降，Mini-batch SGD 既能够有效降低梯度估计方差，批次更新带来的随机噪声也可帮助优化过程跳出局部极小值点，进一步提升训练效果。

3.1.6 学习率动态衰减调度

本实验实现两种主流学习率自适应调度策略，适配不同训练阶段的收敛需求：

- **阶梯衰减（Step Decay）**：固定间隔轮次指数下调学习率，公式定义：

$$\eta_t = \eta_0 \cdot \gamma^{\left\lfloor \frac{t}{T_{\text{step}}} \right\rfloor} \tag{21}$$

- **余弦退火（Cosine Annealing）**：以余弦函数实现学习率平滑周期性衰减：

$$\eta_t = \frac{\eta_0}{2} \cdot \left(1 + \cos\left(\frac{\pi t}{T}\right)\right) \tag{22}$$

最终实验选用阶梯衰减策略，超参数配置为：衰减间隔 $T_{\text{step}} = 25$，衰减倍率 $\gamma = 0.5$，初始学习率 $\eta_0 = 0.01$；即分别在第 25、50、75 个 epoch，将学习率依次衰减为 0.005、0.0025、0.00125。

3.1.7 最优模型保存策略

训练全程引入验证集早停与最优权重留存机制：每完成一个完整 epoch 训练后，立即在独立验证集上评估模型分类准确率。若当前验证准确率优于历史最优指标，则将模型全部权重 $\{W_1, b_1, W_2, b_2, W_3, b_3\}$ 与全套模型超参数配置序列化，持久化存储至本地磁盘（文件命名为 `best_model_final.pkl`）。该策略可全程保留泛化能力最强的模型版本，有效规避训练后期过拟合带来的验证集性能退化问题。

3.1.8 预测与模型保存

在预测阶段，模型通过前向传播得到 logits，并使用 `argmax` 获取预测类别：

$$\hat{y}_i = \arg\max_c Z_{3,i,c} \tag{23}$$

此外，模型还实现了参数保存与加载功能。保存时，所有权重、偏置以及模型配置参数，包括输入维度、隐藏层维度、类别数和激活函数类型均被序列化存储；加载时，根据保存的配置信息重新构建模型，并恢复对应参数。

3.2 超参数搜索

本实验采用网格搜索遍历三个超参数的全部组合，共 $3 \times 3 \times 3 = 27$ 组，每组训练 30 个 epoch，并以验证集最高准确率作为选择依据。

超参数	搜索范围	说明
学习率 η	$\{0.001, 0.01, 0.1\}$	对数均匀间隔
隐藏层维度 h	$\{128, 256, 512\}$	模型容量
L2 正则化系数 λ	$\{0, 0.0001, 0.001\}$	正则化强度

4 实验结果

4.1 训练过程

初始实验按照经验采用如下超参数配置：隐藏层维度为 256，激活函数为 ReLU，初始学习率为 0.01，L2 正则化强度为 1×10^{-4}，训练轮数为 80，批量大小为 128。为改善训练后期的收敛表现，采

用 step 学习率衰减策略，每训练 25 个 epoch 将学习率衰减为原来的 0.5 倍。训练过程各指标变化如下图1所示。

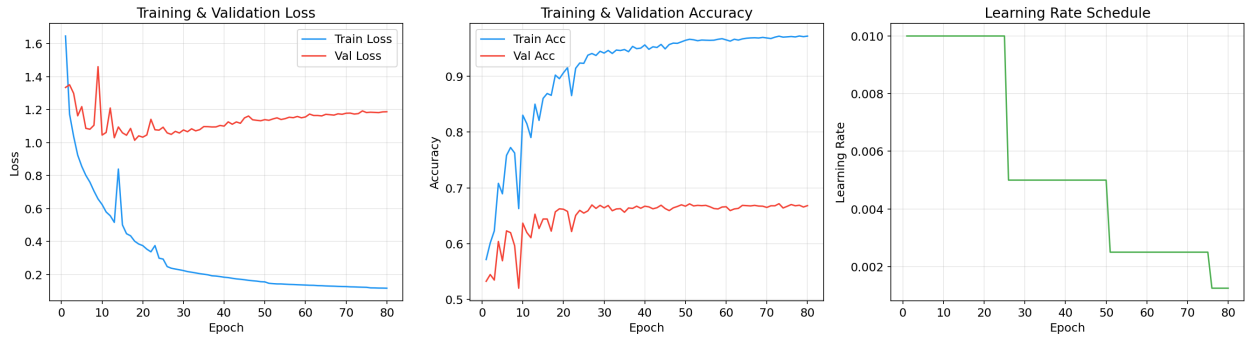

图 1: 最优模型训练过程曲线。左：训练集与验证集 Loss 曲线；中：训练集与验证集 Accuracy 曲线；右：学习率调度曲线

损失曲线分析：训练损失从约 1.65 稳定下降至约 0.12，表明模型在训练集上成功收敛。验证损失在约第 5 个 epoch 达到约 1.45 的峰值后开始下降，并在 30 epoch 后趋于稳定，最终收敛至约 1.18。不过随着 epoch 增加，模型也逐渐出现出过拟合现象。

准确率曲线分析：训练准确率从约 57% 上升至约 97%，验证准确率在经历早期（epoch 1–15）震荡后逐步上升并稳定在约 66.5%。早期震荡源于 mini-batch 梯度的随机性以及初始较大的学习率步长。在第 25 个 epoch 学习率下调后，验证准确率出现小幅上升，说明更精细的步长有助于模型在验证集上进一步优化。

过拟合分析：训练集与验证集之间约 30% 的准确率差距是 MLP 在图像分类任务上固有局限性的体现。MLP 将图像展平为一维向量后失去了所有空间结构信息，只能利用颜色统计特征，导致模型容量虽大却无法学到有效的判别性特征，进而出现过拟合。

4.2 测试集评估结果

训练完成后加载验证集上最优 epoch 对应的模型，在独立测试集上进行评估，最终结果如下表2和图2所示：

通过观察结果可以发现，Forest 和 Pasture 具有高正确率的，分别高达 88.7% 和 80.3%；而 Highway 和 PermanentCrop 则误分类最严重，准确率分别为 42.4% 和 47.5%。

4.3 超参数搜索结果

超参数网格搜索的结果如下图3所示：

从图中可以首先看出学习率的影响最大，$\eta = 0.1$ 时所有配置下验证准确率均约为 0.11，说明学习率过大导致参数在损失曲面上震荡发散，模型完全无法收敛。其次对模型影响加大的是隐藏层维度，更大的网络规模有助于模型学习到更复杂的特征表示；最后对模型影响较小的是权重衰减，它对模型的影响几乎可以忽略不计。

最后训练结束得到最优模型超参数组合为 $\eta^* = 0.01$，$h^* = 512$，$\lambda^* = 0$。

表 2: EuroSAT 各类别分类准确率

类别	正确分类数	总样本数	准确率
AnnualCrop	284	450	63.11%
Forest	399	450	88.67%
HerbaceousVegetation	253	450	56.22%
Highway	159	375	42.40%
Industrial	289	375	77.07%
Pasture	241	300	80.33%
PermanentCrop	178	375	47.47%
Residential	256	450	56.89%
River	229	375	61.07%
SeaLake	353	450	78.44%

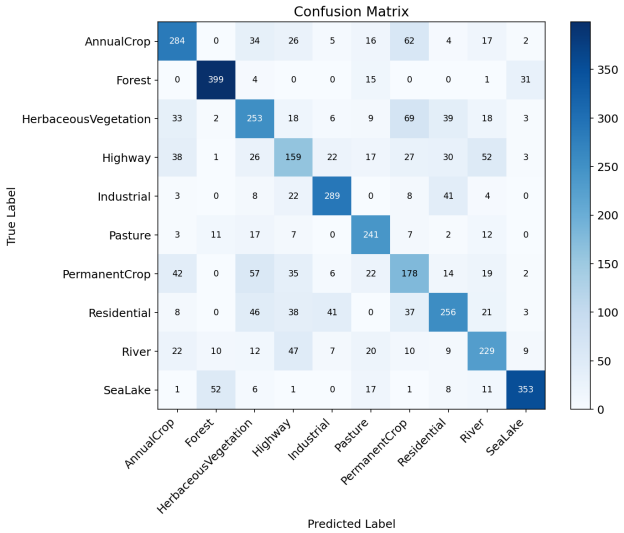

图 2: 测试集混淆矩阵

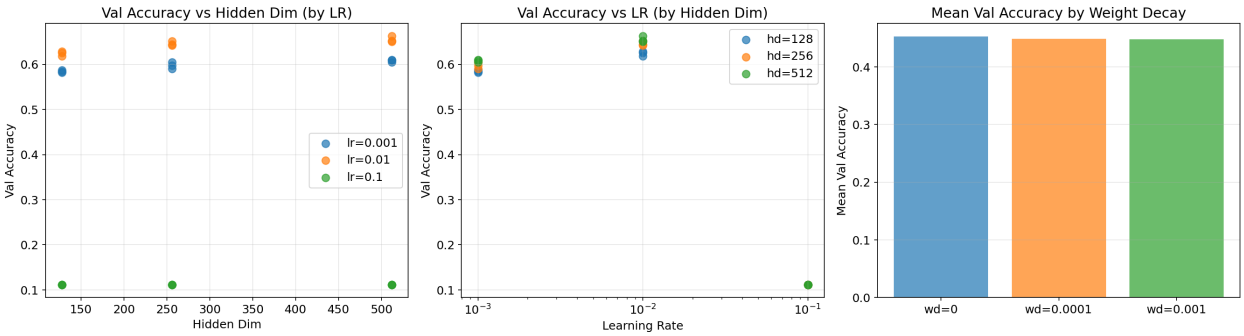

图 3: 超参数搜索结果。左：不同学习率下验证准确率随隐藏层维度的变化；中：不同隐藏层维度下验证准确率随学习率的变化；右：不同权重衰减对应的平均验证准确率。

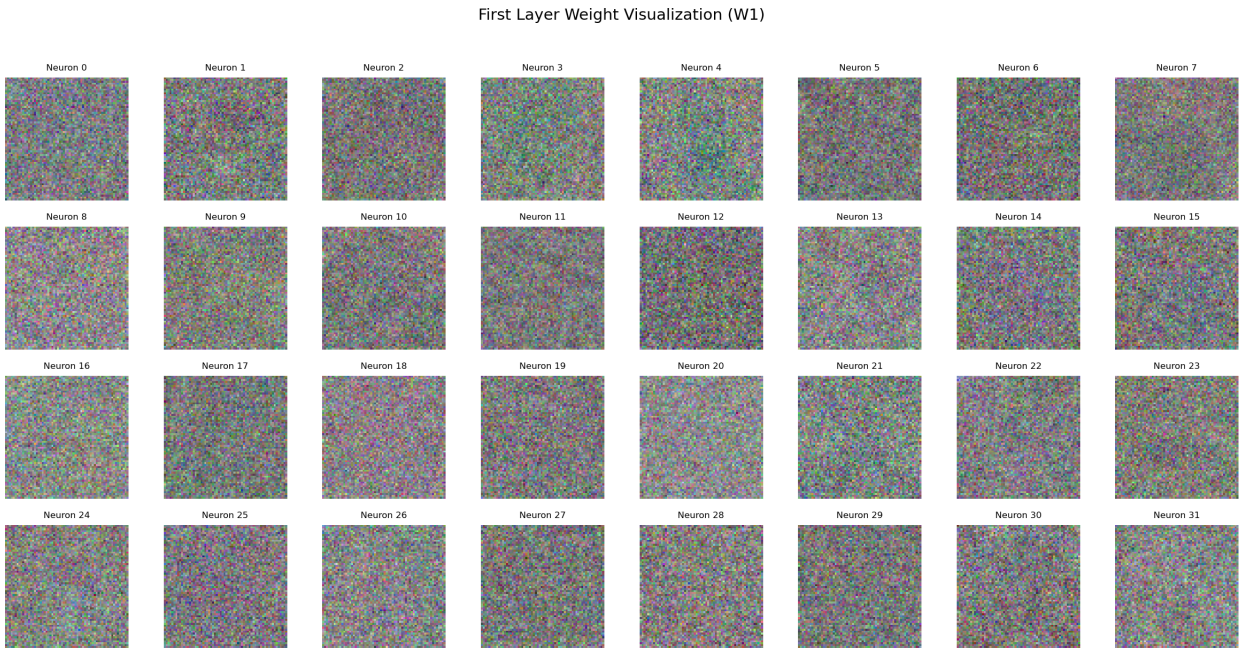

图 4: 第一层隐藏层 W_1 的前 32 个神经元权重可视化

4.4 权重可视化与空间模式分析

接下来为了继续分析权重中是否提取到了某些特定的空间纹理或颜色模式，需要将第一层权重矩阵 W_1 中每个神经元的权重向量还原为 64×64×3 的 RGB 图像，并对像素值进行线性缩放至 [0, 1] 以便可视化。图4展示了前 32 个神经元的权重图像。通过结果图片可以看出，第一层权重未呈现明显的人类可解释的空间或者颜色模式, 整体近似彩色噪声。推测可能是由于 MLP 将图片拉直后，造成了空间信息的丢失。除此之外，只能观察到，某些图像有偏红和偏绿趋势。

4.5 错例分析

最后在试验结束后，从测试集中选取 12 个具有代表性的误分类样本进行定性分析，如图所示5：根据实验结果，大致可以将错误归类为视觉相似导致的错误。以 Residential 被预测为 HerbaceousVegetation 为例，由于住宅区图像含有大量庭院绿化和行道树，像素颜色统计与草本植被高度重叠，叠加上 MLP 无法识别建筑物的几何结构，因此被预测错是可能发生的。以 HerbaceousVegetation 被预测为 AnnualCrop 为例，图中大面积裸土的样子使草地外观更接近农作物田块，所以也容易被预测错误。最后，再以 SeaLake 被预测为 Forest 为例子，图片中深暗色水面与深色常绿针叶林的像素亮度分布相近，因此 MLP 基于颜色统计可能会产生误判。

5 总结

本次实验在不借助任何深度学习框架的前提下，从零实现了一个三层全连接神经网络分类器，并在 EuroSAT 遥感图像数据集上完成了 10 类地表覆盖的分类任务。在方法层面，实验完整实现了前向传播、反向传播与 SGD 优化器，并引入了 He/Xavier 参数初始化、L2 权重衰减正则化与 Step Decay 学习率衰

图 5: 测试集错例分析

减调度策略。在超参数搜索方面，通过 27 组网格搜索实验最终确定最优配置为 $\eta^* = 0.01$，$h^* = 512$，$\lambda^* = 0$。在实验结果层面，最优模型在测试集上的整体分类准确率约为 66.22%。Forest、Pasture 等视觉特征鲜明的类别表现最佳，而 Highway 和 PermanentCrop 由于与其他类别存在视觉混淆，分类效果相对较差。本实验也暴露了 MLP 在图像分类任务上的固有局限：将图像展平为一维向量后丢失了空间结构信息，模型只能依赖颜色统计特征进行分类，这直接导致了训练集与验证集之间约 30% 的准确率差距以及第一层权重无法形成可解释空间模式的现象。未来若引入卷积神经网络，利用局部感受野保留空间关系，预期可显著提升分类精度。

6 代码与资源

本实验的全部代码已上传至公开的 GitHub 仓库，训练得到的最优模型权重文件托管于 Google Drive。相关链接如下：

- **GitHub 仓库：** https://github.com/Ciao-Financialworld/HW1-3Layer-NN-Land-Cover-Classification.git

- **模型权重下载：** https://drive.google.com/file/d/your-file-id/view?usp=sharing